

* MODEL JEDNOSTAVNE LINEARNE REGRESIJE (JEDNA ULAZNA VARIJABLA)

1

m - BROJ PODATAKA

x - ULAZNA VARIJABLA

y - IZLAZNA VARIJABLA

MODEL FUNKCIJA

CILJ: PRONAĆI FUNKCIJU $h_0: \mathbb{R} \rightarrow \mathbb{R}$, $h_0(x) = \theta_0 + \theta_1 x$ T.D. $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_0(x^{(i)}))^2 \rightarrow \min_{\theta}$

* PSEUDOGRAĐIVNI METODE:

1. POSTAVI $\theta^{(1)}$ NA POČETNU VRIJEDNOST

2. ODABERI PROIZVOLJNU DULJINU KORAKA $\alpha > 0$

3. POSTAVI $k=0$

4. POKUŠAJI OD KONVERGENCIJE (TJ. KAD $\| \nabla J(\theta^{(k)}) \| \leq \epsilon$ Ili $k \geq k_{max}$)

$$\theta^{(k+1)} \leftarrow \theta^{(k)} - \alpha \nabla J(\theta^{(k)})$$

$$k \leftarrow k+1$$

5. VRATI $\theta^{(k)}$

$$\nabla J(\theta^{(k)}) = \frac{1}{m} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)}) x^{(i)} = 0 \text{ KADA } = (X\theta - 1)^T X$$

* MODEL VIŠESTRUKNE LINEARNE REGRESIJE (VIŠE ULAZNIH VARIJABLI)

m - BROJ VARIJABLI

n - BROJ PODATAKA

$X = [x_i^{(j)}]_{n \times m}$ MATRICA DIZAJNA

$y = [y^{(i)}]_{n \times 1}$ IZLAZ

MODEL FUNKCIJA: $h_0(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_m x_m = \theta^T x$

$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_m \end{bmatrix}$ - PARAMETRI
DIFERENCIJALNE

$x = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}$ - ULAZ

- OPTIMIZACIJSKI PROBLEM $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_0(x^{(i)}))^2 \rightarrow \min_{\theta}$

* POLINOMNA REGRESIJA

- MODEL FUNKCIJU IZ POLINOMNE REGRESIJE $h_0(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \dots + \theta_n x^n$

ZAPIŠEMO U KONTEKSTU LINEARNE REGRESIJE $h_0(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \dots + \theta_n x_n$

GOJE JE $x = x_1$, $x^2 = x_1^2$, $x^3 = x_1^3$, \dots , $x^n = x_1^n$

* FEATURE SCALING

- UGRADIMO METODE KAO STANDARD SCALER Ili MINMAX SCALER

* ODREĐIVANJE PARAMETARA θ POMUĆU SISTAVA NORMALNIH JEDNAČENI

$$\theta = (X^T X)^{-1} X^T y$$

- AKO $X^T X$ NIJE REGULARNA TJ. NEMA INVERZ KORISTIMO PSEUDOINVERZ

METODA POTPORNIH VEKTORA (SVM)

2

- CILJ JE SEPARIRATI PODATKE HIPERRAVNIKOM T.D. GEOMETRIJSKA RAZDALJINA BUDU MAXIMIZIRANA (OVOJE JE GEOMETRIJSKA RAZDALJINA $= \frac{1}{\|w\|}$)
- PODATCI NE MOGU BITI LINEARNO SEPARABILNI (UVODIMO SLABE VARIJABLE)
- OPTIMIZACIJSKI PROBLEM: $\min_{\theta, \xi} \frac{1}{2} \|\theta\|^2 + C \sum_{i=1}^n \xi_i$, UZ USLOJE $y^{(i)} \theta^T x^{(i)} \geq 1 - \xi_i, \xi_i \geq 0, i=1, \dots, n$
- VERODNE FUNKCIJE :- LINEARNE Ili SVL
 - LINEARNE ILI SVL, ILI NE RAČUNA POTPORNE VEKTORE

KLOBIZIČKA REGRESIJA

- KLASIFIKACIJA PODATAKA MODEL FUNKCIJOM $h_{\theta}: \mathbb{R}^n \rightarrow \{0, 1\}$, $h_{\theta}(x) = \sigma(\theta^T x)$
- Gdje je $\sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$ Sigmoid
- ZA PODATOK $x^{(i)}$ MODEL FUNKCIJE VRAĆA VERODATNOST DA JE $x^{(i)}$ KLASA 1
- OPTIMIZACIJSKI PROBLEM: $J(\theta) = \sum_{i=1}^n \log(1 + e^{-y^{(i)} \theta^T x^{(i)}}) \rightarrow \min_{\theta}$ (ZA $y^{(i)} \in \{-1, 1\}$)
- FUNKCIJA $J(\theta)$ KONVEKSIJNA, MOGUĆE JE RJEŠAVAN GRADISJENTNOM METODOM
- LIKEL-HOD FUNKCIJA: $J^*(\theta) = \prod_{i=1}^n P(y^{(i)} | \theta; x^{(i)}) \rightarrow \max_{\theta}$ DVOJOM FUNKCIJOM MAXIMIZIRAMO VERODATNOST DA JE SVAK PODATAK ISPRAVNO KLASIFICIRAN
- OPTIMIZACIJSKI PROBLEM: $J(\theta) = \sum_{i=1}^n [-y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$ (ZA $y^{(i)} \in \{0, 1\}$)

STUHAŠTIČKA GRADISJENTNA METODA

- ODABIROM VIŠE SLUČAJNO ODABIRANJA $i \in \{1, \dots, m\}$ POMAKNUTI EMO PARAMETRE θ U SMJERU TRENUTNOG GRADISJENTA

FLEWOKOJ STOHAŠTIČKE GRADISJENTNE METODE

1. POSTAVI θ NA POČETNU VRIJEDNOST
2. PONAVLJAJ DO KONVERGENCIJE
 - ODABER $i \in \{1, \dots, m\}$ SLUČAJNIM ODABIROM
 - $\theta \leftarrow \theta - \alpha \nabla_{\theta} \log(h_{\theta}(x^{(i)}), y^{(i)})$

3x3 MATRICE ZABANE

$$\begin{array}{|c|c|c|} \hline 0 & 1 & \\ \hline 0 & 1 & TP \\ \hline 1 & FP & TP \\ \hline \end{array}$$

ACCURACY = $\frac{TP + TN}{N}$

PRECISION = $\frac{TP}{TP + FP}$

RECALL = $\frac{TP}{TP + FN}$

SOFT-MAX REGRESIJA

- GENERALIZIRATI KONCEPT LOGISTIČKE REGRESIJE ZA VIŠEKLASNU KLASIFIKACIJU
- T.D. JE MODEL FUNKCIJA $h_{\theta}: \mathbb{R}^n \rightarrow \mathbb{R}^K$, $h_{\theta}(x) = \begin{bmatrix} P(y=1 | x; \theta) \\ P(y=2 | x; \theta) \\ \vdots \\ P(y=K | x; \theta) \end{bmatrix} = \sigma \left(\begin{bmatrix} \theta_1^T x \\ \theta_2^T x \\ \vdots \\ \theta_K^T x \end{bmatrix} \right) = \frac{1}{\sum_{j=1}^K e^{\theta_j^T x}} \begin{bmatrix} e^{\theta_1^T x} \\ e^{\theta_2^T x} \\ \vdots \\ e^{\theta_K^T x} \end{bmatrix}$
- USLOJE: $\sum_{i=1}^K P(y=i | \theta; x) = 1$
- OPTIMIZACIJSKI PROBLEM: $J(\theta) = \sum_{i=1}^n \sum_{j=1}^K I(y^{(i)} = j) \log \left(\frac{e^{\theta_j^T x^{(i)}}}{\sum_{k=1}^K e^{\theta_k^T x^{(i)}}} \right) \rightarrow \min_{\theta}$

PROBLEMI KLASIFIKACIJE

MODEL FUNKCIJE ODREKA $h_\theta: \mathbb{R}^n \rightarrow \{0, 1, \dots, L-1\}$

ZA DANE KLASNE VARIJABLE $h_\theta(x) = \arg \max (\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n) = \arg \max (\theta^T x)$

PRIMCI $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\} \subset \mathbb{R}^n$ S PRIPADNIM KLASAMA $y^{(i)} \in \{0, 1, \dots, L-1\}$

PRIMCI $\{(x^{(i)}, y^{(i)}) | i=1, \dots, m\}$ SU LINEARNO SEPARABILNI KADA IZDRŽIŠTE AKO VAŽI $y^{(i)} \theta^T x^{(i)} \geq 0 \quad \forall i=1, \dots, m$

LOSS FUNKCIJA / OPTIMIZACIJSKI KRITERIJUM: $J(\theta) = \frac{1}{m} \sum_{i=1}^m (1 - \sigma(h_\theta(x^{(i)} y^{(i)}))) \rightarrow \min_\theta$

$J(\theta) = 0$ AKO SU
SVI SEPARABILNI

$$\sigma(a, b) = \begin{cases} 1, & a=b \\ 0, & a \neq b \end{cases}$$

PERCEPTRON ALGORITHM

CHS: PRONAĐI HIPERRAVNINU $\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n = 0$ KOJA SEPARIRA ULAZNE PRIMERKE NA DVE KLASKE 1 I KLASKE -1

ZA PRIMERKE X KLASKE 1 VAŽIŠTO JE $\theta^T x \geq 0$, A KLASKE -1 $\theta^T x < 0$
VEKTOR θ JE NORMALA HIPERRAVNI

AKO JE $m=2$, HIPERRAVNINA JE PRAVA OPISAN JEDNAČINOM $y = -\frac{\theta_1}{\theta_2} x - \frac{\theta_0}{\theta_2}$

PSEUDOKOD PERCEPTRON ALGORITHM

1. POSTAVI $\theta^{(0)} = (0, \dots, 0)$
2. POSTAVI $k=0$
3. REPEAT
4. FOR $i=1$ TO m
5. IF $y^{(i)} \neq h_{\theta^{(k)}}(x^{(i)})$
6. $\theta^{(k+1)} \leftarrow \theta^{(k)} + y^{(i)} x^{(i)}$ PVR
7. $k \leftarrow k+1$
8. UNTIL $y^{(i)} \theta^{(k)} x^{(i)} \geq 0, \forall i=1, \dots, m$

GEOMETRIJSKA MARGINA - NAJMANJA UDALJENOST IZMEĐU PRAVAKA I HIPERRAVNI $\theta^T x = 0$
- ODNOSI $\gamma^* = \frac{\theta_0 + X \theta}{\|\theta\|}$

FUNKCIJSKA MARGINA - NAJMANJI BROJ γ ZA KOJEG VAŽIŠTO $y^{(i)} \theta^T x^{(i)} \geq \gamma, \forall i=1, \dots, m$

* PRENAUČENOST / OVERFITTING - MODEL FUNKCIJA IMA PREVELIK BROJ PARAMETARA

- DOBRO FITTA TRAIN I TEST DATKE

* PODNAUČENOST / UNDERFITTING - MODEL FUNKCIJA IMA MALKO BROJ PARAMETARA

- LOŠE FITTA I TRAIN I TEST DATKE

* REGULARIZACIJA

- DODAVANJE REGULARIZACIJSKE FUNKCIJE $R: \mathbb{R}^n \rightarrow \mathbb{R}$ U LOŠU FUNKCIJU KAKO BI SE KONTROLIRAO UTJECAJ PARAMETARA θ U MODEL FUNKCIJI h_θ

- UVODI SE U SVRHU SPREČAVANJA OVERFITTINGA

NOVA LOŠA FUNKCIJA: $J(\theta) + R(\theta)$

- ZA R LAR UZIMAMO L_2 NORMU I HIPERPARAMETAR λ

- ZA LINEARNU REGRESIJU ODREĐENU LOŠU FUNKCIJU: $J(\theta) = \frac{1}{2n} \sum_{i=1}^n (y^{(i)} - h_\theta(x^{(i)}))^2 + \lambda \sum_{j=1}^n \theta_j^2$

- ZA SOFT-MAX REGRESIJU - II: $J(\theta) = - \sum_{i=1}^n \sum_{j=1}^K I(i, j) \log \left(\frac{e^{\theta_j^T x^{(i)}}}{\sum_{k=1}^K e^{\theta_k^T x^{(i)}}} \right) + \lambda \sum_{j=1}^K \theta_j^2$

- ZA REGRESIJU SA SUSTAVOM NORMALNIH KVADRATA: $\theta = \left(X^T X + \lambda \begin{bmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{bmatrix} \right)^{-1} X^T Y$

-> λ MALKO - OVERFITTING OSTAJE OVERFITTING

-> λ PREVELIK - OVERFITTING POSTAJE UNDERFITTING

* SUBGRADIJENT

- SVAKI KOEFICIJENT SMJERA PRAVCA KOJI ZADOVOLJAVA DA PODRŽAVA HIPERPLANU KOJA SE U POTPUNOSTI NALAZI ISPOD KONVEKSNE FUNKCIJE

KORISTIMO ZA KONVEKSNE FUNKCIJE KOJE IMAJU TČPIC