

* MODEL JEDNOSTAVNE LINEARNE REGRESIJE (JEDNA ULAZNA VARIJABLA)

1

m - BROJ PODATAKA

x - ULAZNA VARIJABLA

y - IZLAZNA VARIJABLA

MODEL FUNKCIJA

- CIL: PRONAĆI FUNKCIJU $h_0: \mathbb{R} \rightarrow \mathbb{R}$, $h_0(x) = \theta_0 + \theta_1 x$ T.O. $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_0(x^{(i)}))^2 \rightarrow \min_{\theta}$

PSEUDOGRAĐIJENTNA METODA

1. POSTAVI $\theta^{(1)}$ NA POČETNU VRIJEDNOST

2. ODABERI PROIZVODJAK DULJINU KORAKA $\alpha > 0$

3. POSTAVI $k=0$

4. POKRENI DO KONVERGENCIJE (T.J. KADA $\|\nabla J(\theta^{(k)})\|_2 < \epsilon$, $k \geq k_{max}$)

$$\theta^{(k+1)} \leftarrow \theta^{(k)} - \alpha \nabla J(\theta^{(k)})$$

$$k \leftarrow k+1$$

5. VRAZI θ^k

$$\nabla J(\theta^{(k)}) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)}) x^{(i)} = 0 \text{ KODU} = (X^T X - I)^T X$$

* MODEL VIŠESTRUKNE LINEARNE REGRESIJE (VIŠE ULAZNIH VARIJABLI)

n - BROJ VARIJABLI

m - BROJ PODATAKA

$X = [x_i^{(j)}]_{m \times n}$ MATRICA DIZAJNA

$y = [y^{(i)}]_{m \times 1}$ IZLAZ

MODEL FUNKCIJA: $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n = \theta^T x$

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \text{ - PARAMETRI HIPEREBRANKE} \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} \text{ - VLAZ}$$

- OPTIMIZACIJSKI PROBLEM $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)}))^2 \rightarrow \min_{\theta}$

* POLINOMNA REGRESIJA

- MODEL FUNKCIJU IZ POLINOMNE REGRESIJE $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \dots + \theta_n x^n$

ZAPIŠEMO U KONTEKSTU LINEARNE REGRESIJE $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \dots + \theta_n x_n$

GOJE JE $x = x_1$, $x^2 = x_1^2$, $x^3 = x_1^3$, ..., $x^n = x_1^n$

* FEATURE SCALING

- UVRABEĆE METODE KAO STANDARDIZACIJA ILI MIN-MAX SCALING

* ODREĐIVANJE PARAMETARA θ POMUĆU SISTAVA NORMALNIH JEDNAČENI

$$\theta = (X^T X)^{-1} X^T y$$

- AKO $X^T X$ NIJE REGULARNA T.J. NEMA INVERZ KORISTIMO PSEUDOINVERZ

* METODA POTPORNIH VEKTORA (SVM)

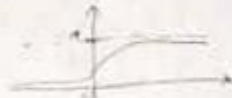
2

- CILJ JE SEPARIRATI PODATKE HIPERPRAVNOM T.O. GEOMETRIJSKA MARGINA BUDE MAKSIMIZIRANA (OVOJE JE GEOMETRIJSKA MARGINA = $\frac{1}{\|w\|} = \frac{1}{\text{AF. LINEAR. NORM. (NORM. VEC. NER.)}}$)
- PODACI NE MORAJU BITI LINEARNO SEPARABILNI (UVODIMO SLACK VARIJABLE)
- OPTIMIZACIJSKI PROBLEM: $\min_{\theta, \xi} \frac{1}{2} \|\theta\|^2 + C \sum_{i=1}^n \xi_i$ UZ USLOJE $\theta^T x^{(i)} \geq 1 - \xi_i, \xi_i \geq 0, i=1, \dots, n$
- UVRADENE FUNKCIJE: - LINEARNE ILI IVE

- LINEARNE JE BRŽE, ALI NE RAČUNO POTPORNE VEKTORE

* LOGISTIČKA REGRESIJA

- KLASIFIKACIJA PODATAKI MODEL FUNKCIJOM $h_{\theta}: \mathbb{R}^n \rightarrow \{0, 1\}$, $h_{\theta}(x) = \Theta(\theta^T x)$

GOJE JE $\Theta(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$ I GLEDAJ 

- ZA PODATAK $x^{(i)}$ MODEL FUNKCIJE VRAĆA VEROJATNOST DA JE $x^{(i)}$ KLASA 1

- OPTIMIZACIJSKI PROBLEM: $J(\theta) = \sum_{i=1}^n \log(1 + e^{-\theta^T x^{(i)}}) \rightarrow \min_{\theta}$ (ZA $y^{(i)} \in \{0, 1\}$)

- POŠTO JE $J(\theta)$ KONVEKSIJAN, MOŽE SE REŠAVATI GRADIJENTNOM METODOM

- LIKELIHOOD FUNKCIJA: $J'(\theta) = \prod_{i=1}^n P(y^{(i)} | \theta; x^{(i)}) \rightarrow \max_{\theta}$ DVOJOM FUNKCIJOM MAKSIMIZIRAMO VEROJATNOST DA JE PRAVA, KATAK ISPRAVNO KLASIFIKACIJAN

- OPTIMIZACIJSKI PROBLEM: $J(\theta) = \sum_{i=1}^n [-y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$ (ZA $y^{(i)} \in \{0, 1\}$)

* STUPOSTIČKA GRADIJENTNA METODA

- GRADIJENTOM VIŠE SLUČAJNO ODABIRANIH $x \in \{1, \dots, m\}$ POKREKNUT EMO PARAMETAR θ U SMJERU TAČNOG GRADIJENTA

* PREDVODNA STOHAŠTIČKA GRADIJENTNA METODA

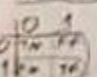
1. POSTAVI θ NA POČETNU VRIJEDNOST

2. PONAVLJAJI DO KONVERGENCIJE

ODABERI $i \in \{1, \dots, m\}$ SLUČAJNIM ODABIRAN

$\theta \leftarrow \theta - \alpha \nabla_{\theta} \log(h_{\theta}(x^{(i)}, y^{(i)}))$

* MATRICA ZABUNE

 ACCURACY = $\frac{TP + TN}{N}$

PRECISION = $\frac{TP}{TP + FP}$

RECALL = $\frac{TP}{TP + FN}$

* SOFT-MAX REGRESIJA

- GENERALIZIRATI KONCEPT LOGISTIČKE REGRESIJE ZA VIŠEKLASNU KLASIFIKACIJU T.O. JE MODEL FUNKCIJA $h_{\theta}: \mathbb{R}^n \rightarrow \mathbb{R}^K$, $h_{\theta}(x) = \begin{bmatrix} P(y=1|x; \theta) \\ P(y=2|x; \theta) \\ \vdots \\ P(y=K|x; \theta) \end{bmatrix} = \Theta \left(\begin{bmatrix} \theta^{(1)T} x \\ \theta^{(2)T} x \\ \vdots \\ \theta^{(K)T} x \end{bmatrix} \right) = \frac{1}{\sum_{j=1}^K e^{\theta^{(j)T} x}} \begin{bmatrix} e^{\theta^{(1)T} x} \\ e^{\theta^{(2)T} x} \\ \vdots \\ e^{\theta^{(K)T} x} \end{bmatrix}$

- SVOJSTVO: $\sum_{j=1}^K P(y=j|\theta; x) = 1$

- OPTIMIZACIJSKI PROBLEM: $J(\theta) = \sum_{i=1}^n \sum_{j=1}^K I(y^{(i)}=j) \log \left(\frac{e^{\theta^{(j)T} x^{(i)}}}{\sum_{k=1}^K e^{\theta^{(k)T} x^{(i)}}} \right) \rightarrow \min_{\theta}$

$\nabla J(\theta) = \frac{\partial J}{\partial \theta} = \frac{\partial J}{\partial \theta^{(j)}} \frac{\partial \theta^{(j)}}{\partial \theta}$

PROBLEMI KLASIFIKACIJE

MODEL FUNKCIJA CELOKUPNO $h_\theta: \mathbb{R}^n \rightarrow \{0, 1, \dots, k-1\}$

ZA DVA KLASICE VRIJEDI: $h_\theta(x) = \text{sign}(\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n) = \text{sign}(\theta^T x)$

PODACI $\{x^{(1)}, x^{(2)}, \dots, x^{(n)}\} \subset \mathbb{R}^n$ I PRIDRUŽENIM KLASAMA $y^{(i)} \in \{-1, 1\}$

PODACI $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(n)}, y^{(n)})\}$ SU LINEARNO SEPARABILNI KADA ISPODJE AKO

VRIJEDI $y^{(i)} \theta^T x^{(i)} \geq 0 \quad \forall i=1, \dots, n$

LOSS FUNKCIJA / OPTIMIZACIJSKI PROBLEM: $J(\theta) = \frac{1}{n} \sum_{i=1}^n (1 - \sigma(h_\theta(x^{(i)} y^{(i)}))) \rightarrow \min_\theta$

$J(\theta) = 0$ AKO SU
SVI SEPARABILNI

$$\sigma(a) = \begin{cases} 1, & a \geq 0 \\ 0, & a < 0 \end{cases}$$

PERCEPTRON ALGORITHM

CIJ: PROMENI HIPERRAVNINU $\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n = 0$ KOJA SEPARIRA ULAZNE

PODACI NA DVA KLASICE 1 I KLASICE -1

ZA POSEBNU KLASICE 1 VRIJEDI DA $\theta^T x \geq 0$, A KLASICE -1 $\theta^T x < 0$

VEKTOR $\vec{\theta}$ JE NORMALA HIPERRAVNI

AKO JE $m=2$, HIPERRAVNINA JE PRAVA ODREĐENA JEDNAKOŠEM $y = -\frac{\theta_1}{\theta_2} x - \frac{\theta_0}{\theta_2}$

PSEUDOKOD PERCEPTRON ALGORITHM

1. POSTAVI $\theta^{(0)} = (0, \dots, 0)$

2. POSTAVI $k=0$

3. REPET

FOR $i=1$ TO n

5. IF $y^{(i)} \neq h_{\theta^{(k)}}(x^{(i)})$

6. $\theta^{(k+1)} \leftarrow \theta^{(k)} + y^{(i)} x^{(i)}$ FOR

7. $k \leftarrow k+1$

8. UNTIL $y^{(i)} \theta^{(k)} x^{(i)} \geq 0, \forall i=1, \dots, n$

$$\theta_0 + \theta_1 x + \theta_2 y = 0$$

GEOMETRISKA MARGINA - NAJMANJA UDALJENOST IZMEĐU PODATKA I HIPERRAVNI $\vec{\theta}^T x = 0$

$$\text{MARGA } \mu = \frac{\theta_0 + x \vec{\theta}}{\|\vec{\theta}\|}$$

FUNKCIJSKA MARGINA - NAJMANJE BROJ μ ZA KOJEG VRIJEDI $y^{(i)} \theta^T x^{(i)} \geq \mu, \forall i=1, \dots, n$

* PRENAUČENOST / OVERFITTING - MODEL FUNKCIJA IMA PREVELIK BROJ PARAMETARA

- DOBRO FITTA TRAIN, ALI LOŠE TEST PODATKE

* PODMAUČENOST / UNDERFITTING - MODEL FUNKCIJA IMA PREMAL BROJ PARAMETARA

- LOŠE FITTA I TRAIN I TEST PODATKE

* REGULARIZACIJA

- DODAVANJE REGULARIZACIJSKE FUNKCIJE $R: \mathbb{R}^m \rightarrow \mathbb{R}$ U LOSS FUNKCIJU KAKO BI SE KONTROLIRAO UTJECAJ PARAMETARA θ U MODEL FUNKCIJI h_θ

- UVODI SE U SVRHU SPRJEČAVANJA OVERFITTINGA

- NOVA LOSS FUNKCIJA: $J(\theta) + R(\theta)$

- ZA R NPR UZMEMO L_2 NORMU I HIPERPARAMETAR λ

- ZA LINEARNU REGRESIJU DOBIJEMO LOSS FUNKCIJU: $J(\theta) = \frac{1}{2n} \sum_{i=1}^n (y^{(i)} - h_\theta(x^{(i)}))^2 + \lambda \sum_{j=1}^n \theta_j^2$

- ZA SOFT-MAX REGRESIJU IMAMO: $J(\theta) = - \sum_{i=1}^n \sum_{j=1}^K I(y^{(i)} = j) \log \left(\frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^K e^{\theta_l^T x^{(i)}}} \right) + \lambda \sum_{j=1}^K \sum_{i=1}^n \theta_{j,i}^2$

- ZA REGRESIJU SA SUSTAVOM NORMALNIH JEDNAČENI: $\theta = \left(X^T X + \lambda \begin{bmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{bmatrix} \right)^{-1} X^T Y$

$\Rightarrow \lambda$ PREMAL - OVERFITTING OSTANE OVERFITTING

$\Rightarrow \lambda$ PREVELIK - OVERFITTING POSTAJE UNDERFITTING

* SUBGRADIJENT

- SVAKI KOEFICIJENT IMAJE PRAVCA KOJI ZADOVOLJAVA DA PODZELI HIPERPLANOM

KOJA SE U POTPUNOSTI NALAZI ISPOD KONVEKSNE FUNKCIJE

- KORISTIMO ZA KONVEKSNE FUNKCIJE KOJE IMAJU 1. TIPIC